AlexNet et DHVT pour la classification d'images

Haobo YANG 22513870
Zhenyu XU 22508276

Université Paris Cité

Année universitaire 2025–2026

Plan

1. Objectif
2. Architecture
3. Résultats
4. Conclusion

Question du projet

- On compare un **CNN classique** et une architecture **de type transformer** sur des petits jeux de données d'images.
- Le baseline est **AlexNet** ; le modèle principal est **DHVT**.
- La question centrale est simple : **comment rendre un ViT plus efficace sur un petit dataset ?**

Point de départ : le CNN [1]

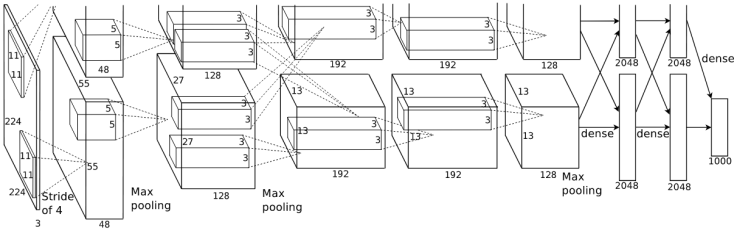

AlexNet

- Il utilise des **convolutions**.
- Il apprend d'abord des **motifs locaux**.
- Limite : il capture moins bien les relations **globales**.

$$Y_{i,j} = \sum_u \sum_v K_{u,v} X_{i+u,j+v}$$

Vue d'ensemble de DHVT [2] [3]

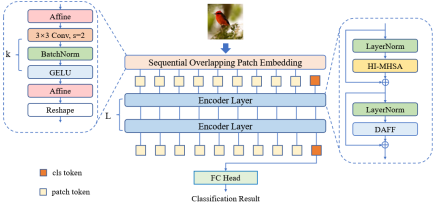

- **SOPE** → ajoute une entrée de type plus **convolutionnelle**, donc plus locale.
- **HI-MHSA** → garde la partie **globale** du transformer.
- **DAFF** → remet de la **convolution** dans le bloc interne, donc une logique plus proche du CNN.

Résumé de la structure

Module	Ce qui change	Pourquoi c'est utile
SOPE	Nouvelle entrée	Garde mieux l'information locale
HI-MHSA	Nouvelle attention	Organise mieux l'information globale
DAFF	Nouveau bloc interne	Rajoute du local dans le transformer

- En résumé, **DHVT garde le global du transformer**.
- Mais il **récupère aussi le local**, ce qui est utile sur les petites images.

Résultat principal

Mesure	CIFAR-10	CIFAR-100
Accuracy AlexNet / DHVT	0.6848 / 0.7762	0.2856 / 0.5012
Écart d'accuracy	+0.0914	+0.2156
F1 macro AlexNet / DHVT	0.6814 / 0.7759	0.2713 / 0.4958
Paramètres AlexNet / DHVT	58.32M / 6.80M	58.69M / 6.81M

- DHVT est **meilleur sur les deux jeux de données**.
- L'écart devient **beaucoup plus grand sur CIFAR-100**.
- Le modèle est aussi **bien plus compact** qu'AlexNet.

Les figures confirment la conclusion

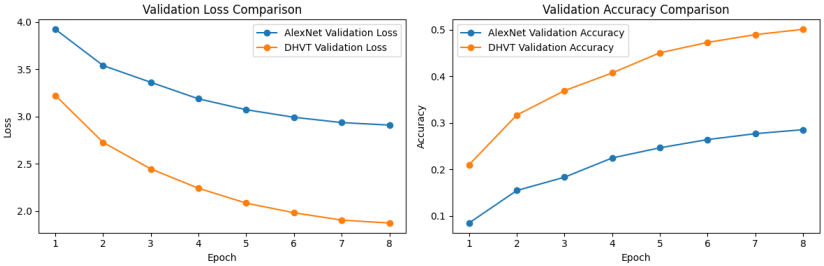

- C'est la figure la plus importante car **CIFAR-100** est le cas le plus difficile.
- DHVT apprend **plus vite**.
- Il reste **au-dessus d'AlexNet** pendant tout l'entraînement.
- Donc son avantage n'apparaît pas seulement à la fin.

La confiance des prédictions est plus cohérente

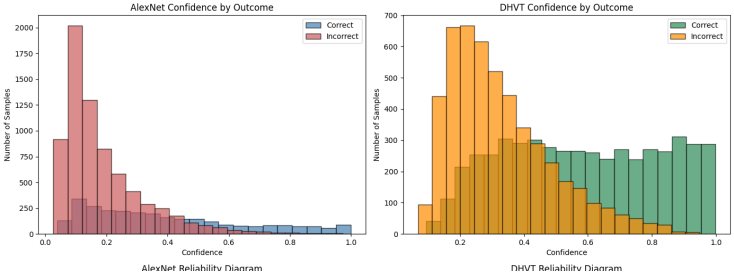

- DHVT sépare mieux les **bonnes** et les **mauvaises** prédictions.
- Donc ses scores de confiance sont plus **cohérents**.
- Ce n'est pas seulement un meilleur score final.

Le gain n'est pas limité à quelques classes

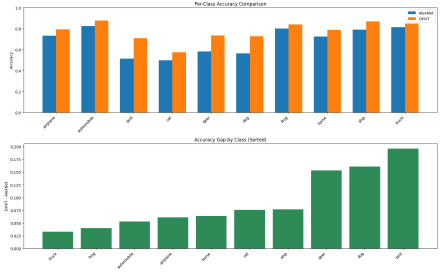

- L'écart entre DHVT et AlexNet est **positif pour toutes les classes**.
- Le gain n'est donc pas limité à quelques classes faciles.
- L'avantage de DHVT est **global**.

Exemples d'erreurs de classification

- On voit ici des **cas difficiles**.
- Dans plusieurs exemples, **DHVT corrige** une erreur d'AlexNet.
- Les erreurs restantes viennent souvent d'images **petites** ou **ambiguës**.

Cartes d'attention de DHVT

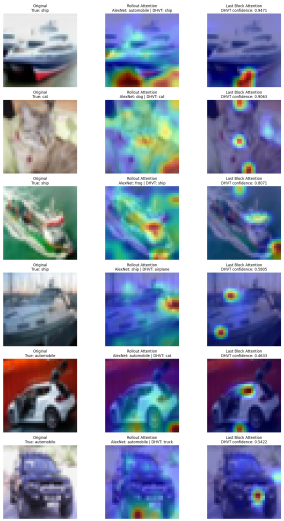

- Les cartes montrent **où DHVT regarde**.
- Sur les bons exemples, l'attention vise souvent l'**objet principal**.
- Sur les erreurs, elle est plus **diffuse**.

Résultats sur les variantes de CIFAR-100

Variante	AlexNet acc.	DHVT acc.	Écart
clean	0.2694	0.5167	+0.2472
texture	0.2583	0.4278	+0.1694
damaged_occluded	0.2944	0.4222	+0.1278
long_range	0.3333	0.4472	+0.1139

- DHVT reste **meilleur sur toutes les variantes**.
- L'avantage est maximal sur `clean`.
- Mais il reste présent sur toutes les autres variantes.
- Donc le gain n'est pas limité à un seul type de difficulté.

Conclusion

- Le **CNN** est fort pour le **local**.
- Le **ViT** est fort pour le **global**.
- **DHVT** essaie de combiner les deux.
- Dans nos expériences, cela donne **de meilleurs résultats qu'AlexNet**, surtout sur les cas difficiles.

Références

1. Krizhevsky, A., Sutskever, I., and Hinton, G. E. *ImageNet Classification with Deep Convolutional Neural Networks*. Advances in Neural Information Processing Systems (NeurIPS), 2012.
2. Dosovitskiy, A. et al. *An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale*. International Conference on Learning Representations (ICLR), 2021.
3. Lu, Y. et al. *Bridging the Gap Between Vision Transformers and Convolutional Neural Networks on Small Datasets*. arXiv preprint arXiv:2203.16353, 2022.

Merci

Merci pour votre attention

Questions ?

Annexe : SOPE

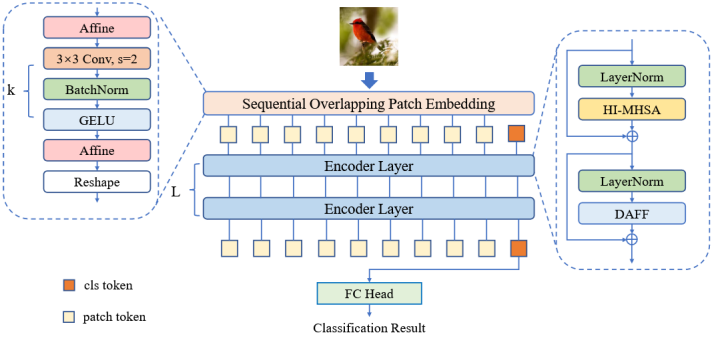

- SOPE remplace l'entrée par patches trop directe.
- L'idée est de garder plus d'information locale dès le début.
- Donc les tokens d'entrée sont plus adaptés aux petites images.

Annexe : HI-MHSA

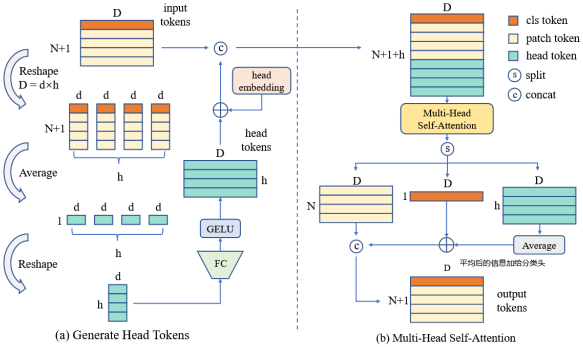

- HI-MHSA modifie le bloc d'attention.
- Les *head tokens* aident à mieux organiser l'information globale.
- Le but est d'obtenir une meilleure représentation finale pour la classification.

Annexe : DAFF

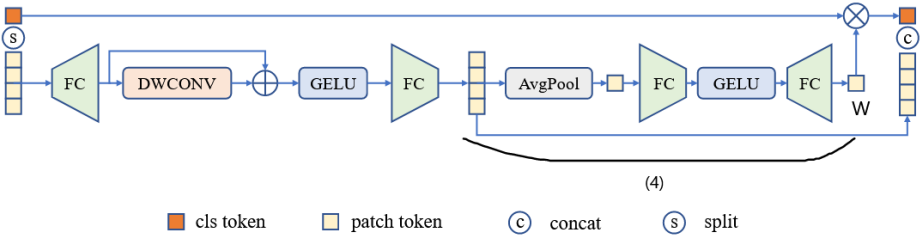

- DAFF remplace le FFN standard.
- Il ajoute une partie locale dans le bloc transformer.
- Cela aide DHVT à combiner information locale et information globale.